TEMA: L1. Proiectarea studiului de caz

Sisteme Informaționale Integrate
Sistem federativ de integrare a datelor olimpice

Indicativ echipă: **SIA04**

STABILIRE SURSE DE DATE EXTERNE

Dataset utilizat: *120 Years of Olympic History – Athletes and Results* (Kaggle)
`https://www.kaggle.com/datasets/heesoo37/120-years-of-olympic-history-athletes-and-re`
Baza de date centrală: Oracle Cloud Autonomous Database 26ai (Always Free Tier)
Schema federativă: FDBO

Cuprins

1 DS_1: Oracle – Date de referință olimpice 3
1.1 Descriere sursă de date . . . 3
1.2 Descriere structuri de date . . . 3
1.2.1 Tabelul SPORTS (66 rânduri) . . . 3
1.2.2 Tabelul EVENTS (765 rânduri) . . . 3
1.2.3 Tabelul GAMES (52 rânduri) . . . 3
1.2.4 Tabelul COUNTRIES (230 rânduri) . . . 4
1.3 Legături între structuri . . . 4
1.4 Implementare sursă de date externă . . . 4
1.4.1 Script DDL – Creare tabele (CLOUD_02_OLY_REF_TABLES.sql) 4
1.4.2 Script DML – Inserare date (exemplu) . . . 5

2 DS_2: PostgreSQL – Date tranzacționale atleți și rezultate 6
2.1 Descriere sursă de date . . . 6
2.2 Descriere structuri de date . . . 6
2.2.1 Tabelul PG_ATHLETES (135.571 rânduri) . . . 6
2.2.2 Tabelul PG_RESULTS (271.116 rânduri) . . . 6
2.3 Legături între structuri . . . 7
2.4 Implementare sursă de date externă . . . 7
2.4.1 Script DDL – Creare tabele PostgreSQL (03.create_pg.sql) . . . 7
2.4.2 Script DDL – Tabele Oracle echivalente (CLOUD_04_FDBO_TABLES.sql) 7
2.4.3 Script DB Link heterogen (08.FDBO_DBLINK_PG.sql) . . . 8

3 DS_3: MongoDB/JSON – Documente NoSQL cu agregări medalii 9
3.1 Descriere sursă de date . . . 9
3.2 Descriere structuri de date . . . 9
3.2.1 Tabelul JSON_MEDAL_DOCS (28.302 rânduri) . . . 9
3.2.2 Structura document athlete_medal (28.251 documente) . . . 9
3.2.3 Structura document game_summary (51 documente) . . . 10
3.3 Legături între structuri . . . 10
3.4 Implementare sursă de date externă . . . 10
3.4.1 Exemplu document JSON – athlete_medal . . . 10
3.4.2 Exemplu document JSON – game_summary . . . 10
3.4.3 Script DDL – Creare tabel Oracle . . . 11
3.4.4 View cu JSON_TABLE (CLOUD_06_FDBO_ACCESS_VIEWS.sql) 11

4 DS_4: CSV – Fișier plat cu date denormalizate 13
4.1 Descriere sursă de date . . . 13
4.2 Descriere structuri de date . . . 13
4.2.1 Tabelul CSV_ATHLETE_EVENTS (50.000 rânduri) . . . 13
4.3 Legături între structuri . . . 13
4.4 Implementare sursă de date externă . . . 14
4.4.1 Exemplu fișier CSV (athlete_events_enriched.csv) . . . 14
4.4.2 Script DDL – Creare tabel Oracle . . . 14

5 Sumar surse de date 15

1 DS_1: Oracle – Date de referință olimpice

1.1 Descriere sursă de date

Parametru	Valoare
Nume sursă	Baza de date Oracle – date de referință Jocuri Olimpice
Descriere	Sporturi, evenimente, ediții olimpice și țări/comitete olimpice naționale. Schema: OLY_REF. Accesată din schema FDBO prin GRANT SELECT cross-schema.
Tip sursă de date	Bază de date relațională Oracle
Tip model de date	Relațional
Tip format de acces	SQL

1.2 Descriere structuri de date

1.2.1 Tabelul SPORTS (66 rânduri)

Câmp	Tip	Descriere
sport_id	NUMBER, PK	Identificator unic sport
sport_name	VARCHAR2(100), NOT NULL, UNIQUE	Denumirea sportului (ex: Athletics, Swimming, Gymnastics)

1.2.2 Tabelul EVENTS (765 rânduri)

Câmp	Tip	Descriere
event_id	NUMBER, PK	Identificator unic eveniment
sport_id	NUMBER, FK → SPORTS	Sportul din care face parte
event_name	VARCHAR2(200), NOT NULL	Denumirea completă (ex: “Men’s 100 metres”)

1.2.3 Tabelul GAMES (52 rânduri)

Câmp	Tip	Descriere
game_id	NUMBER, PK	Identificator unic ediție
games_name	VARCHAR2(50), NOT NULL, UNIQUE	Denumirea ediției (ex: “2016 Summer”)
year	NUMBER(4), NOT NULL	Anul ediției
season	VARCHAR2(10), NOT NULL	Sezonul: Summer sau Winter
city	VARCHAR2(100), NOT NULL	Orașul gazdă (ex: Rio de Janeiro)

1.2.4 Tabelul COUNTRIES (230 rânduri)

Câmp	Tip	Descriere
noc	VARCHAR2(3), PK	Codul comitetului olimpic (ex: ROU, USA)
region	VARCHAR2(100), NOT NULL	Denumirea țării (ex: Romania)
notes	VARCHAR2(200)	Observații (ex: "former country")

1.3 Legături între structuri

- EVENTS.sport_id → SPORTS.sport_id (FK – fiecare eveniment aparține unui sport)

1.4 Implementare sursă de date externă

1.4.1 Script DDL – Creare tabele (CLOUD_02_OLY_REF_TABLES.sql)

Listing 1: Creare tabele OLY_REF

```sql
CREATE TABLE OLY_REF.SPORTS (
    sport_id     NUMBER PRIMARY KEY,
    sport_name   VARCHAR2(100) NOT NULL UNIQUE
);

CREATE TABLE OLY_REF.EVENTS (
    event_id     NUMBER PRIMARY KEY,
    sport_id     NUMBER NOT NULL REFERENCES OLY_REF.SPORTS(sport_id),
    event_name   VARCHAR2(200) NOT NULL
);

CREATE TABLE OLY_REF.GAMES (
    game_id      NUMBER PRIMARY KEY,
    games_name   VARCHAR2(50) NOT NULL UNIQUE,
    year         NUMBER(4) NOT NULL,
    season       VARCHAR2(10) NOT NULL,
    city         VARCHAR2(100) NOT NULL
);

CREATE TABLE OLY_REF.COUNTRIES (
    noc      VARCHAR2(3) PRIMARY KEY,
    region   VARCHAR2(100) NOT NULL,
    notes    VARCHAR2(200)
);

GRANT SELECT ON OLY_REF.SPORTS TO FDBO;
GRANT SELECT ON OLY_REF.EVENTS TO FDBO;
GRANT SELECT ON OLY_REF.GAMES TO FDBO;
GRANT SELECT ON OLY_REF.COUNTRIES TO FDBO;
```

1.4.2 Script DML – Inserare date (exemplu)

Listing 2: Inserare date referință (exemplu)

```sql
INSERT INTO OLY_REF.SPORTS VALUES (1, 'Aeronautics');
INSERT INTO OLY_REF.SPORTS VALUES (2, 'Alpine Skiing');
INSERT INTO OLY_REF.SPORTS VALUES (3, 'Archery');
INSERT INTO OLY_REF.SPORTS VALUES (4, 'Art Competitions');
INSERT INTO OLY_REF.SPORTS VALUES (5, 'Athletics');

INSERT INTO OLY_REF.GAMES VALUES (1, '1896 Summer', 1896, 'Summer',
    'Athina');
INSERT INTO OLY_REF.GAMES VALUES (2, '1900 Summer', 1900, 'Summer',
    'Paris');
INSERT INTO OLY_REF.GAMES VALUES (3, '1904 Summer', 1904, 'Summer',
    'St. Louis');

INSERT INTO OLY_REF.COUNTRIES VALUES ('ROU', 'Romania', NULL);
INSERT INTO OLY_REF.COUNTRIES VALUES ('USA', 'USA', NULL);
INSERT INTO OLY_REF.COUNTRIES VALUES ('GBR', 'UK', NULL);

INSERT INTO OLY_REF.EVENTS VALUES (1, 5, 'Men''s 100 metres');
INSERT INTO OLY_REF.EVENTS VALUES (2, 5, 'Men''s 200 metres');
INSERT INTO OLY_REF.EVENTS VALUES (3, 5, 'Women''s 100 metres');
```

Scripturi complete: CLOUD_01_CREATE_USERS.sql, CLOUD_02_OLY_REF_TABLES.sql, CLOUD_03_OLY_REF_DATA.sql, CLOUD_03b_OLY_REF_EVENTS.sql, setup_oracle_cloud.p

2 DS_2: PostgreSQL – Date tranzacționale atleți și rezultate

2.1 Descriere sursă de date

Parametru	Valoare
Nume sursă	Baza de date PostgreSQL – date tranzacționale
Descriere	Toți atleții din istoria olimpică (135.571) și fiecare participare la fiecare eveniment (271.116). PostgreSQL 16 local. Importate în Oracle Cloud prin ETL Python (echivalent DB Link heterogen).
Tip sursă de date	Bază de date relațională PostgreSQL
Tip model de date	Relațional
Tip format de acces	SQL

2.2 Descriere structuri de date

2.2.1 Tabelul PG_ATHLETES (135.571 rânduri)

Câmp	Tip	Descriere
athlete_id	NUMBER, PK	Identificator unic atlet
full_name	VARCHAR2(300), NOT NULL	Numele complet (ex: "Michael Fred Phelps, II")
sex	CHAR(1)	Sexul: M sau F
birth_year	NUMBER(4)	Anul nașterii
birth_place	VARCHAR2(200)	Locul nașterii
height_cm	NUMBER(5,1)	Înălțimea în cm (ex: 193)
weight_kg	NUMBER(5,1)	Greutatea în kg (ex: 90)
noc	VARCHAR2(3)	Codul țării

2.2.2 Tabelul PG_RESULTS (271.116 rânduri)

Câmp	Tip	Descriere
result_id	NUMBER, PK	Identificator unic participare
athlete_id	NUMBER, NOT NULL	Atletul care a participat
game_id	NUMBER	Ediția la care a participat
event_id	NUMBER	Evenimentul la care a participat
medal	VARCHAR2(10)	Gold, Silver, Bronze sau NULL
age	NUMBER(3)	Vârsta la momentul participării
team	VARCHAR2(200)	Echipa (ex: "Romania")
noc	VARCHAR2(3), NOT NULL	Codul țării

2.3 Legături între structuri

- PG_RESULTS.athlete_id → PG_ATHLETES.athlete_id (FK – fiecare rezultat aparține unui atlet)
- PG_RESULTS.game_id → GAMES.game_id (legătură logică spre DS_1)
- PG_RESULTS.event_id → EVENTS.event_id (legătură logică spre DS_1)
- PG_RESULTS.noc → COUNTRIES.noc (legătură logică spre DS_1)

2.4 Implementare sursă de date externă

2.4.1 Script DDL – Creare tabele PostgreSQL (03.create_pg.sql)

Listing 3: Creare tabele PostgreSQL

```sql
CREATE TABLE athletes (
    athlete_id  SERIAL PRIMARY KEY,
    name        VARCHAR(300) NOT NULL,
    sex         CHAR(1),
    height      REAL,
    weight      REAL
);

CREATE TABLE results (
    result_id   SERIAL PRIMARY KEY,
    athlete_id  INTEGER NOT NULL REFERENCES athletes(athlete_id),
    game_id     INTEGER,
    event_id    INTEGER,
    medal       VARCHAR(10),
    age         INTEGER,
    team        VARCHAR(200),
    noc         VARCHAR(3) NOT NULL
);
```

2.4.2 Script DDL – Tabele Oracle echivalente (CLOUD_04_FDBO_TABLES.sql)

Listing 4: Tabele FDBO pentru date PostgreSQL

```sql
CREATE TABLE FDBO.PG_ATHLETES (
    athlete_id  NUMBER PRIMARY KEY,
    full_name   VARCHAR2(300) NOT NULL,
    sex         CHAR(1),
    birth_year  NUMBER(4),
    birth_place VARCHAR2(200),
    height_cm   NUMBER(5,1),
    weight_kg   NUMBER(5,1),
    noc         VARCHAR2(3)
);

CREATE TABLE FDBO.PG_RESULTS (
```

```
    result_id    NUMBER PRIMARY KEY,
    athlete_id   NUMBER NOT NULL,
    game_id      NUMBER,
    event_id     NUMBER,
    medal        VARCHAR2(10),
    age          NUMBER(3),
    team         VARCHAR2(200),
    noc          VARCHAR2(3) NOT NULL
);
```

2.4.3 Script DB Link heterogen (08.FDBO_DBLINK_PG.sql)

Listing 5: DB Link Oracle → PostgreSQL (necesită Oracle local)

```
CREATE DATABASE LINK pg_olympics_link
CONNECT TO "olympics" IDENTIFIED BY "olympics"
USING 'pg_hs';

CREATE OR REPLACE VIEW FDBO.PG_ATHLETES_REMOTE AS
SELECT * FROM "athletes"@pg_olympics_link;

CREATE OR REPLACE VIEW FDBO.PG_RESULTS_REMOTE AS
SELECT * FROM "results"@pg_olympics_link;
```

Notă: DB Link-ul heterogen nu este suportat pe Oracle Cloud Autonomous Database. Datele au fost importate prin ETL Python (load_to_oracle.py), care face același lucru – aduce datele din PostgreSQL în Oracle.

Scripturi complete: 00.SCHEMA_pg.sql, 01.staging_pg.sql, 03.create_pg.sql, 04.insert_pg.sql, CLOUD_04_FDBO_TABLES.sql, load_to_oracle.py, 08.FDBO_DBLINK_PG.sql

3 DS_3: MongoDB/JSON – Documente NoSQL cu agregări medalii

3.1 Descriere sursă de date

Parametru	Valoare
Nume sursă	Colecție de documente JSON (simulare MongoDB)
Descriere	Două tipuri de documente: sumarizări medalii per atlet (28.251) și statistici per ediție olimpică (51). Stocate în Oracle cu coloană CLOB JSON, accesate prin JSON_TABLE.
Tip sursă de date	Bază de date NoSQL orientată pe documente (MongoDB)
Tip model de date	Ierarhic / Document (JSON)
Tip format de acces	JSON

3.2 Descriere structuri de date

3.2.1 Tabelul JSON_MEDAL_DOCS (28.302 rânduri)

Câmp	Tip	Descriere
doc_id	NUMBER, PK, auto-increment	Identificator unic document
doc_type	VARCHAR2(50), NOT NULL	Tipul: 'athlete_medal' sau 'game_summary'
json_data	CLOB	Documentul JSON brut

3.2.2 Structura document athlete_medal (28.251 documente)

Câmp JSON	Tip	Descriere
name	string	Numele atletului
total_medals	number	Numărul total de medalii
gold	number	Medalii de aur
silver	number	Medalii de argint
bronze	number	Medalii de bronz
sports_count	number	Sporturi la care a participat
games_count	number	Ediții la care a participat

3.2.3 Structura document game_summary (51 documente)

Câmp JSON	Tip	Descriere
games_name	string	Denumirea ediției (ex: “2016 Summer”)
year	number	Anul
season	string	Summer sau Winter
city	string	Orașul gazdă
total_athletes	number	Numărul total de atleți
total_entries	number	Numărul total de participări
countries_count	number	Țări participante
events_count	number	Număr evenimente

3.3 Legături între structuri

- Legătură logică: athlete_medal.name ↔ PG_ATHLETES.full_name
- Legătură logică: game_summary.games_name ↔ GAMES.games_name

3.4 Implementare sursă de date externă

3.4.1 Exemplu document JSON – athlete_medal

Listing 6: Document JSON athlete_medal

```
{
  "athlete_id": 41939,
  "name": "Michael Fred Phelps, II",
  "sex": "M",
  "total_medals": 28,
  "gold": 23,
  "silver": 3,
  "bronze": 2,
  "sports_count": 1,
  "games_count": 5,
  "first_game_id": 25,
  "last_game_id": 51
}
```

3.4.2 Exemplu document JSON – game_summary

Listing 7: Document JSON game_summary

```
{
  "game_id": 51,
  "games_name": "2016 Summer",
  "year": 2016,
  "season": "Summer",
  "city": "Rio de Janeiro",
  "total_athletes": 11179,
  "total_entries": 13688,
```

```
  "medals": {
    "total": 2023,
    "gold": 669,
    "silver": 668,
    "bronze": 686
  },
  "countries_count": 207,
  "events_count": 306
}
```

3.4.3 Script DDL – Creare tabel Oracle

Listing 8: Tabel pentru documente JSON

```
CREATE TABLE FDBO.JSON_MEDAL_DOCS (
    doc_id     NUMBER GENERATED ALWAYS AS IDENTITY PRIMARY KEY,
    doc_type   VARCHAR2(50) NOT NULL,
    json_data CLOB,
    CONSTRAINT chk_json CHECK (json_data IS JSON)
);

CREATE INDEX idx_json_doc_type ON FDBO.JSON_MEDAL_DOCS(doc_type);
```

3.4.4 View cu JSON_TABLE (CLOUD_06_FDBO_ACCESS_VIEWS.sql)

Listing 9: Acces JSON prin JSON_TABLE

```
CREATE OR REPLACE VIEW FDBO.FDBO_JSON_ATHLETE_MEDALS_V AS
SELECT
    j.doc_id,
    jt.athlete_name,
    jt.total_medals,
    jt.gold_medals,
    jt.silver_medals,
    jt.bronze_medals,
    jt.sports_count,
    jt.games_count,
    'MongoDB/JSON' AS data_source
FROM FDBO.JSON_MEDAL_DOCS j,
     JSON_TABLE(j.json_data, '$'
         COLUMNS (
             athlete_name   VARCHAR2(300) PATH '$.name',
             total_medals   NUMBER(5)     PATH '$.total_medals',
             gold_medals    NUMBER(5)     PATH '$.gold',
             silver_medals  NUMBER(5)     PATH '$.silver',
             bronze_medals  NUMBER(5)     PATH '$.bronze',
             sports_count   NUMBER(5)     PATH '$.sports_count',
             games_count    NUMBER(5)     PATH '$.games_count'
         )
     ) jt
WHERE j.doc_type = 'athlete_medal';
```

Fișiere sursă: mongo_data/athlete_medals_docs.jsonl, mongo_data/game_summary_docs.jsonl
Scripturi: prepare_data.py, load_to_oracle.py, CLOUD_06_FDBO_ACCESS_VIEWS.sql

4 DS_4: CSV – Fișier plat cu date denormalizate

4.1 Descriere sursă de date

Parametru	Valoare
Nume sursă	Fișier CSV denormalizat enriched
Descriere	Primele 50.000 de rânduri din dataset-ul original Kaggle, îmbogățit cu coloana "region" (denumirea țării). Simulează import de date dintr-un fișier plat extern.
Tip sursă de date	Fișier text structurat
Tip model de date	Tabular / Plat (denormalizat)
Tip format de acces	CSV

4.2 Descriere structuri de date

4.2.1 Tabelul CSV_ATHLETE_EVENTS (50.000 rânduri)

Câmp	Tip	Descriere
row_id	NUMBER, PK	Identificator rând
athlete_name	VARCHAR2(300)	Numele atletului
sex	VARCHAR2(2)	Sexul: M sau F
age	NUMBER(3)	Vârsta
height	NUMBER(5,1)	Înălțimea
weight	NUMBER(5,1)	Greutatea
team	VARCHAR2(200)	Echipa
noc	VARCHAR2(3)	Codul țării
games	VARCHAR2(50)	Ediția (ex: "1988 Winter")
year	NUMBER(4)	Anul
season	VARCHAR2(10)	Sezonul
city	VARCHAR2(100)	Orașul
sport	VARCHAR2(100)	Sportul
event	VARCHAR2(200)	Evenimentul
medal	VARCHAR2(10)	Medalia sau NULL
region	VARCHAR2(100)	Țara (coloana enriched)

4.3 Legături între structuri

- Datele sunt denormalizate (fără FK-uri), dar câmpurile corespund logic cu:
- noc ↔ COUNTRIES.noc (DS_1)
- games ↔ GAMES.games_name (DS_1)
- sport ↔ SPORTS.sport_name (DS_1)
- event ↔ EVENTS.event_name (DS_1)

4.4 Implementare sursă de date externă

4.4.1 Exemplu fișier CSV (athlete_events_enriched.csv)

Listing 10: Primele rânduri din CSV

```
row_id,athlete_name,sex,age,height,weight,team,noc,games,year,
    season,city,sport,event,medal,region
1,Christine Jacoba Aaftink,F,21,185.0,82.0,Netherlands,NED,1988
    Winter,1988,Winter,Calgary,Speed Skating,Women's 500 metres,,
    Netherlands
2,Christine Jacoba Aaftink,F,21,185.0,82.0,Netherlands,NED,1988
    Winter,1988,Winter,Calgary,Speed Skating,Women's 1000 metres,,
    Netherlands
3,Christine Jacoba Aaftink,F,25,185.0,82.0,Netherlands,NED,1992
    Winter,1992,Winter,Albertville,Speed Skating,Women's 500 metres
    ,,Netherlands
```

4.4.2 Script DDL – Creare tabel Oracle

Listing 11: Tabel pentru date CSV

```
CREATE TABLE FDBO.CSV_ATHLETE_EVENTS (
    row_id          NUMBER PRIMARY KEY,
    athlete_name    VARCHAR2(300),
    sex             VARCHAR2(2),
    age             NUMBER(3),
    height          NUMBER(5,1),
    weight          NUMBER(5,1),
    team            VARCHAR2(200),
    noc             VARCHAR2(3),
    games           VARCHAR2(50),
    year            NUMBER(4),
    season          VARCHAR2(10),
    city            VARCHAR2(100),
    sport           VARCHAR2(100),
    event           VARCHAR2(200),
    medal           VARCHAR2(10),
    region          VARCHAR2(100)
);
```

Fișier sursă: csv_data/athlete_events_enriched.csv
Scripturi: prepare_data.py, load_to_oracle.py, CLOUD_04_FDBO_TABLES.sql

5 Sumar surse de date

DS	Tehnologie	Model	Format	Rânduri
DS_1	Oracle (OLY_REF)	Relațional	SQL	1.113
DS_2	PostgreSQL (FDBO.PG_*)	Relațional	SQL	406.687
DS_3	MongoDB/JSON (FDBO.JSON_*)	Ierarhic/Document	JSON	28.302
DS_4	CSV (FDBO.CSV_*)	Tabular/Plat	CSV	50.000
TOTAL				**486.102**